

Credit scoring et classification du risque de crédit

Analyse des profils de risque à partir du jeu de données HELOC et comparaison de modèles de classification

BATY Elouann

20/07/2026

Licence 3 Mathématiques et Informatique Appliquées aux Sciences Humaines et Sociales

Table des matières

I – Résumé	5
II – Introduction	5
1. Contexte et intérêt du credit scoring	5
2. Problématique et question de recherche	6
3. Objectifs de l'étude	6
4. Organisation du rapport.....	7
III – Données et préparation de la base	7
1. Présentation du jeu de données HELOC.....	7
2. Description des variables	8
3. Qualité des données	9
4. Prétraitement des données	9
5. Analyse descriptive	10
6. Comparaison des profils Good et Bad.....	10
7. Analyse des corrélations	11
8. Synthèse de l'analyse exploratoire	12
IV – Modélisation du risque de crédit	12
1. Stratégie de modélisation	12
2. Régression logistique	13
3. Random Forest.....	14
4. Gradient Boosting	14
5. Comparaison des modèles.....	15
6. Analyse des erreurs.....	16
7. Courbes ROC et capacité discriminante	17
8. Choix du modèle final	18
V – Interprétation des résultats	19
1. Importance des variables dans les modèles d'arbre	19
2. Comparaison des variables entre Good et Bad	20
3. Interprétation de la régression logistique	20
4. Lecture économique et financière des résultats	21
5. Limites de l'interprétation.....	21
VI – Evaluation critique et limites du modèle.....	22
1. Performance prédictive.....	22
2. Déséquilibre et coût des erreurs.....	22

3. Interprétabilité.....	23
4. Limites des données	23
5. Limites méthodologiques.....	24
6. Pistes d'amélioration	24
VII – Conclusion	25
1. Réponse à la problématique	25
2. Principaux résultats.....	25
3. Apports du projet.....	25
4. Perspectives	26
VIII – Sources et références.....	26
1. Données.....	26
2. Méthodes et outils.....	26
3. Références institutionnelles	27
Annexes	28
Annexe A – Description complète des variables	28
Annexe B – Statistiques descriptives complètes	29
Annexe C – Résultats détaillés de la régression logistique	30
Annexe D – Scripts et éléments techniques.....	31

I – Résumé

Le credit scoring constitue un outil essentiel dans l'évaluation du risque associé à l'octroi de crédit. L'objectif de cette étude est d'analyser dans quelle mesure les caractéristiques financières et comportementales d'un emprunteur permettent de prédire son niveau de risque et d'identifier les variables les plus déterminantes dans cette classification.

L'analyse repose sur le jeu de données *HELOC (Home Equity Line of Credit)*, composé de **10 459 observations et de 23 variables explicatives**, ainsi que d'une variable cible **RiskPerformance** distinguant les profils **Good** et **Bad**. Une phase de préparation des données a été réalisée afin de traiter les valeurs particulières et les valeurs manquantes, puis une analyse exploratoire a permis d'étudier les principales caractéristiques de la population et les différences entre les deux catégories de risque.

Trois méthodes de classification ont ensuite été comparées : **la régression logistique, le Random Forest et le Gradient Boosting**. Leurs performances ont été évaluées à partir de plusieurs indicateurs complémentaires, notamment l'accuracy, la précision, le rappel, le F1-score et le ROC-AUC. L'analyse est complétée par une étude de l'importance des variables et par l'interprétation des coefficients de la régression logistique.

Les résultats montrent que les modèles permettent de distinguer les deux catégories de profils avec des performances relativement proches, tout en mettant en évidence plusieurs caractéristiques importantes du risque de crédit, notamment celles liées à l'estimation externe du risque, à l'historique de crédit, aux demandes récentes et à l'utilisation des crédits. L'étude permet ainsi de mettre en évidence l'intérêt des méthodes d'apprentissage supervisé pour le credit scoring, tout en soulignant l'importance de l'interprétabilité et des limites liées aux données et aux choix méthodologiques.

II – Introduction

1. Contexte et intérêt du credit scoring

L'octroi de crédit constitue une activité majeure pour les établissements financiers et implique une évaluation préalable du risque associé à chaque emprunteur. Lorsqu'un établissement accorde un crédit, il s'expose en effet à la possibilité que l'emprunteur ne respecte pas ses engagements. L'évaluation de ce risque représente donc un enjeu important, aussi bien pour limiter les pertes potentielles que pour améliorer la qualité des décisions d'octroi.

Le credit scoring désigne l'ensemble des méthodes permettant d'évaluer ou de prédire le niveau de risque d'un emprunteur à partir d'informations relatives à sa situation et à son historique de crédit. Les méthodes statistiques et, plus récemment, les techniques d'apprentissage automatique permettent de construire des modèles capables de distinguer différents profils de risque à partir de données historiques.

L'intérêt de ces méthodes ne repose toutefois pas uniquement sur leur capacité prédictive. Dans un domaine tel que le crédit, il est également nécessaire de comprendre les facteurs associés aux décisions

du modèle. L'identification des variables les plus importantes et l'interprétation de leur relation avec le risque constituent ainsi des dimensions complémentaires à l'évaluation de la performance.

Ce projet s'inscrit dans cette perspective en combinant une analyse statistique des données avec plusieurs méthodes de classification afin d'étudier la prédiction du risque de crédit et les caractéristiques permettant de différencier les profils étudiés.

2. Problématique et question de recherche

À partir du jeu de données HELOC, l'objectif est d'étudier la capacité de différentes méthodes de classification à distinguer les emprunteurs selon leur niveau de risque. La variable RiskPerformance permet de distinguer deux catégories, Good et Bad, qui constituent la cible des modèles étudiés.

La question de recherche retenue est donc la suivante :

Dans quelle mesure les caractéristiques financières et comportementales d'un emprunteur permettent-elles de prédire son niveau de risque de crédit, et quelles sont les variables les plus déterminantes dans cette classification ?

Cette problématique implique deux objectifs complémentaires. Il s'agit d'une part de déterminer si les modèles étudiés permettent d'obtenir une classification suffisamment performante. D'autre part, il s'agit d'identifier et d'interpréter les caractéristiques qui contribuent le plus à la distinction entre les deux catégories de profils.

3. Objectifs de l'étude

L'objectif principal de cette étude est de construire et d'évaluer des modèles permettant de prédire le risque de crédit à partir des caractéristiques disponibles dans la base HELOC. Plusieurs objectifs secondaires en découlent :

- comprendre la structure et la qualité du jeu de données
- préparer les données en traitant les valeurs particulières et les valeurs manquantes
- caractériser les profils étudiés à l'aide d'une analyse descriptive
- comparer les caractéristiques des profils Good et Bad
- étudier les relations entre les variables explicatives
- construire plusieurs modèles de classification
- comparer leurs performances à l'aide de plusieurs métriques
- analyser les erreurs de classification
- identifier les variables les plus importantes pour les modèles d'arbre
- interpréter les coefficients et les odds ratios de la régression logistique
- discuter les limites des modèles et les possibilités d'amélioration

4. Organisation du rapport

Le rapport est organisé en plusieurs parties complémentaires. La première partie présente le contexte du credit scoring, la problématique étudiée et les objectifs de l'analyse.

La deuxième partie est consacrée aux données et à leur préparation. Elle présente le jeu de données HELOC, les variables utilisées, la qualité de la base, les traitements réalisés ainsi que les principaux résultats de l'analyse exploratoire.

La troisième partie présente la démarche de modélisation et compare les performances de la régression logistique, du Random Forest et du Gradient Boosting. Une attention particulière est portée à l'analyse des erreurs, aux courbes ROC et au choix du modèle final.

La quatrième partie approfondit l'interprétation des résultats en étudiant l'importance des variables dans les modèles d'arbre, les différences entre les profils Good et Bad et les coefficients de la régression logistique.

La cinquième partie propose une évaluation critique des modèles et présente leurs principales limites ainsi que plusieurs pistes d'amélioration. Enfin, la conclusion revient sur la problématique initiale, les principaux enseignements de l'étude et les perspectives envisageables.

III – Données et préparation de la base

1. Présentation du jeu de données HELOC

L'étude repose sur le jeu de données *HELOC (Home Equity Line of Credit)*, consacré à l'évaluation du risque de crédit. La base contient **10 459 observations** et **23 variables explicatives**, ainsi qu'une variable cible nommée **RiskPerformance**.

La variable **RiskPerformance** distingue deux catégories de profils : **Good** et **Bad**. Elle constitue la variable à prédire dans les différents modèles de classification développés dans la suite de l'étude.

Les variables explicatives décrivent différentes caractéristiques de l'historique et du comportement de crédit des emprunteurs. Elles renseignent notamment sur l'ancienneté des comptes, le nombre de crédits détenus, leur utilisation, les demandes récentes de crédit ainsi que les éventuels incidents de paiement.

Caractéristique	Valeur
Nombre d'observations	10 459
Nombre de variables explicatives	23
Variable cible	RiskPerformance
Classe Good	47,81 %
Classe Bad	52,19 %

Tableau 3.1 – Caractéristiques générales du jeu de données

La répartition de la variable cible est relativement équilibrée. La classe **Bad** représente **52,19 %** des observations, contre **47,81 %** pour la classe **Good**. Cette répartition constitue un élément favorable pour la modélisation, puisqu'aucune des deux classes n'est très largement majoritaire.




Figure 3.1 – Répartition des profils selon *RiskPerformance*

2. Description des variables

Les 23 variables explicatives disponibles dans la base couvrent plusieurs dimensions du comportement financier des emprunteurs. Elles peuvent être regroupées selon la nature de l'information qu'elles apportent.

Une première catégorie concerne l'ancienneté de l'historique de crédit, avec notamment **MSinceOldestTradeOpen**, **MSinceMostRecentTradeOpen** et **AverageMInFile**. Ces variables permettent de caractériser la durée et la profondeur de l'historique financier disponible.

Une deuxième catégorie regroupe les variables relatives au nombre et à la nature des crédits, telles que **NumTotalTrades**, **NumSatisfactoryTrades**, **NumRevolvingTradesWBalance** ou **NumInstallTradesWBalance**.

Les variables relatives à l'utilisation du crédit permettent quant à elles de mesurer la proportion ou le niveau d'utilisation des différentes lignes de crédit. On retrouve notamment **NetFractionRevolvingBurden**, **NetFractionInstallBurden**, **PercentTradesWBalance** et **PercentInstallTrades**.

Enfin, plusieurs variables décrivent les demandes récentes de crédit et les incidents de paiement. C'est notamment le cas de **NumInqLast6M**, **NumInqLast6Mexcl7days**, **MaxDelqEver** et **MSinceMostRecentDelq**.

Cette diversité de variables permet donc d'étudier le risque de crédit à partir de plusieurs dimensions complémentaires du profil de l'emprunteur.

Dimension	Exemples de variables	Information étudiée
Risque	ExternalRiskEstimate	Estimation externe du risque
Ancienneté	MSinceOldestTradeOpen, AverageMInFile	Historique du crédit
Activité de crédit	NumTotalTrades, NumTradesOpeninLast12M	Volume et activité des crédits
Utilisation	NetFractionRevolvingBurden, PercentTradesWBalance	Niveau d'utilisation du crédit
Demandes	NumInqLast6M, NumInqLast6M excl 7days	Demandes récentes
Incidents	MaxDelqEver, MSinceMostRecentDelq	Historique des incidents

Tableau 3.2 – Principales variables explicatives et dimensions étudiées

3. Qualité des données

Avant toute modélisation, une vérification de la qualité de la base est nécessaire. L'exploration initiale met en évidence la présence de valeurs manquantes ainsi que de plusieurs codes particuliers dans certaines variables.

Les valeurs -7, -8 et -9 ne correspondent pas à des mesures numériques ordinaires. Leur signification est liée à l'absence ou à la non-disponibilité de certaines informations. Elles ne doivent donc pas être interprétées directement comme des valeurs quantitatives.

Code	Traitement
-7	Valeur considérée comme manquante
-8	Valeur considérée comme manquante
-9	Valeur considérée comme manquante

Tableau 3.3 – Codes particuliers identifiés dans la base

Ces codes sont identifiés lors de l'étape de contrôle de la qualité des données afin d'être traités avant la construction des modèles.

4. Prétraitement des données

Après l'identification des problèmes de qualité, une étape de prétraitement est réalisée afin d'obtenir une base exploitable pour la modélisation. Les codes particuliers -7, -8 et -9 sont tout d'abord convertis en valeurs manquantes. Cette transformation permet de ne pas considérer ces codes comme de véritables valeurs numériques.

Les valeurs manquantes présentes dans les variables numériques sont ensuite remplacées par la médiane de la variable concernée. Ce choix permet de conserver l'ensemble des observations tout en limitant l'influence des valeurs extrêmes sur l'imputation.

Étape	Situation
Base initiale	Présence de valeurs manquantes et codes particuliers
Traitement des codes -7/-8/-9	Conversion en valeurs manquantes
Variables numériques	Imputation par la médiane
Base finale	Aucune valeur manquante

Tableau 3.4 – Synthèse du prétraitement des données

À l'issue de ces traitements, un contrôle de la base finale est effectué afin de vérifier l'absence de valeurs manquantes et de s'assurer que les variables peuvent être utilisées par les modèles de classification.

5. Analyse descriptive

Une analyse descriptive est ensuite réalisée afin de caractériser les principales variables numériques de la base finale. Les indicateurs étudiés comprennent notamment la moyenne, la médiane, l'écart-type, ainsi que les valeurs minimale et maximale.

Les variables présentent des échelles et des distributions différentes. Certaines mesurent une ancienneté en mois, tandis que d'autres correspondent à des nombres de crédits, à des proportions ou à des indicateurs liés à l'utilisation du crédit. Les statistiques descriptives permettent ainsi d'obtenir une première vision de la population étudiée et d'identifier les variables présentant une dispersion importante.

Variable	N	Moyenne	Écart-type	Médiane	Min.	Max.
ExternalRiskEstimate	9 861	72,06	9,87	72	33	94
MSinceOldestTradeOpen	9 632	200,77	97,95	186	2	803
NumSatisfactoryTrades	9 871	21,12	11,32	20	0	79
PercentTradesNeverDelq	9 871	92,36	11,77	97	0	100
NumTotalTrades	9 871	22,64	13,00	21	0	104
NumInqLast6M	9 871	1,46	2,14	1	0	66
NetFractionRevolvingBurden	9 685	34,86	28,90	29	0	232
PercentTradesWBalance	9 853	66,45	22,04	67	0	100

Tableau 3.5 Statistiques descriptives des principales variables

Plusieurs variables présentent également des écarts entre leur moyenne et leur médiane, ce qui peut traduire une asymétrie de leur distribution. **NumInqLast6M**, par exemple, présente une médiane faible alors que certaines observations prennent des valeurs nettement plus élevées. Cette hétérogénéité devra être prise en compte lors de l'interprétation des résultats.

6. Comparaison des profils Good et Bad

L'analyse descriptive est complétée par une comparaison des caractéristiques moyennes des deux catégories de **RiskPerformance**. Cette comparaison permet d'identifier les variables pour lesquelles les profils Good et Bad présentent les différences les plus importantes.

ExternalRiskEstimate présente une moyenne de 76,54 chez les profils Good contre 67,96 chez les profils Bad. Une différence importante est également observée pour **AverageMInFile**, avec une moyenne de 86,82 chez les Good contre 71,11 chez les Bad.

Variable	Good — Moyenne	Bad — Moyenne
ExternalRiskEstimate	76,54	67,96
AverageMInFile	86,82	71,11
MSinceOldestTradeOpen	220,03	180,89
NetFractionRevolvingBurden	24,55	43,47
PercentTradesWBalance	60,42	72,03

Tableau 3.6 Comparaison des principales variables selon RiskPerformance

L'ancienneté de l'historique de crédit présente également une différence notable. **MSinceOldestTradeOpen** atteint en moyenne 220,03 mois chez les Good contre 180,89 mois chez les Bad.

À l'inverse, certaines variables liées à l'utilisation du crédit sont plus élevées chez les profils Bad. C'est notamment le cas de **NetFractionRevolvingBurden**, dont la moyenne atteint 43,47 chez les Bad contre 24,55 chez les Good.

Ces différences constituent de premiers éléments permettant de caractériser les profils associés aux deux niveaux de risque. Elles ne permettent cependant pas, à elles seules, d'établir une relation causale entre une variable et le risque : leur intérêt sera évalué plus précisément lors de la modélisation.

7. Analyse des corrélations

Une analyse des corrélations entre les variables explicatives est réalisée afin d'identifier les relations linéaires importantes et de repérer d'éventuelles redondances dans l'information disponible.

La matrice de corrélation met en évidence plusieurs associations fortes entre certaines variables. La corrélation la plus importante est observée entre **NumInqLast6M** et **NumInqLast6Mexcl7days**, avec un coefficient de 0,997. Ces deux variables apportent donc une information très proche concernant les demandes récentes de crédit.




Figure 3.7 – Matrice de corrélation des variables explicatives

Une forte corrélation est également observée entre **NumTrades60Ever2DerogPubRec** et **NumTrades90Ever2DerogPubRec**, avec un coefficient de 0,975. De même, **PercentTradesNeverDelq** et **MaxDelqEver** présentent une corrélation de 0,928.

Ces résultats montrent que certaines variables décrivent des dimensions proches du comportement de crédit. Cette redondance doit être prise en compte lors de l'interprétation des modèles, notamment

pour la régression logistique, pour laquelle des variables fortement corrélées peuvent rendre l'interprétation individuelle des coefficients plus délicate.

Il n'est toutefois pas nécessaire de supprimer automatiquement les variables fortement corrélées. Une corrélation élevée entre deux variables n'implique pas qu'elles soient inutiles pour la prédiction. Leur conservation permet notamment de comparer le comportement des différents modèles et d'évaluer leur contribution à la classification.

8. Synthèse de l'analyse exploratoire

L'analyse exploratoire a permis de caractériser la base HELOC et de mettre en évidence plusieurs éléments importants pour la suite de l'étude.

La variable **RiskPerformance** présente une répartition relativement équilibrée entre les profils Good et Bad, avec une légère majorité de profils Bad. La phase de préparation des données a par ailleurs permis de traiter les codes particuliers et les valeurs manquantes afin d'obtenir une base exploitable pour la modélisation.

L'analyse descriptive montre des différences entre les deux catégories de profils. Les variables liées à l'estimation du risque, à l'ancienneté de l'historique de crédit et à l'utilisation des crédits présentent notamment des écarts entre les profils Good et Bad. Ces différences constituent des premiers éléments permettant d'identifier les caractéristiques potentiellement associées au niveau de risque.

L'analyse des corrélations met enfin en évidence une forte redondance entre certaines variables, notamment celles décrivant les demandes récentes de crédit et certains indicateurs liés aux incidents. Ces relations devront être prises en compte lors de l'interprétation des modèles.

À l'issue de cette phase exploratoire, la base préparée peut être utilisée pour construire et comparer différents modèles de classification. La partie suivante est consacrée à cette étape de modélisation.

IV – Modélisation du risque de crédit

1. Stratégie de modélisation

L'objectif de cette phase est de construire des modèles capables de prédire la variable **RiskPerformance** à partir des caractéristiques disponibles dans la base HELOC. Il s'agit d'un problème de classification binaire, puisque la variable cible comporte deux catégories : **Good** et **Bad**.

Trois méthodes de classification sont étudiées et comparées : **la régression logistique, le Random Forest et le Gradient Boosting**. Le choix de modèles appartenant à des familles différentes permet de comparer une méthode statistique relativement interprétable à deux méthodes d'apprentissage fondées sur des ensembles d'arbres de décision.

Avant l'entraînement, les données ont été préparées conformément aux traitements présentés dans le chapitre précédent. La variable cible est séparée des variables explicatives, puis les observations sont réparties entre un ensemble d'apprentissage et un ensemble de test. L'ensemble d'apprentissage est

utilisé pour construire les modèles, tandis que l'ensemble de test permet d'évaluer leur capacité à généraliser leurs prédictions sur des observations qui n'ont pas été utilisées lors de l'entraînement.

Les performances sont évaluées à l'aide de plusieurs indicateurs complémentaires. L'*accuracy* mesure la proportion globale de classifications correctes. La *precision* mesure la proportion de prédictions positives qui sont effectivement positives, tandis que le *recall* mesure la capacité du modèle à retrouver les observations appartenant à la classe étudiée. Le **F1-score** combine précision et rappel, et le **ROC-AUC** permet d'évaluer la capacité globale du modèle à distinguer les deux classes.

L'utilisation de plusieurs métriques permet d'éviter de limiter l'évaluation à l'*accuracy* et d'obtenir une vision plus complète des performances des modèles. Une attention particulière sera également portée aux erreurs de classification, notamment aux faux négatifs et aux faux positifs, dont l'interprétation est importante dans le contexte du risque de crédit.

2. Régression logistique

La régression logistique constitue le premier modèle retenu pour la classification des profils de risque. Elle permet d'estimer la probabilité qu'une observation appartienne à l'une des deux catégories de la variable **RiskPerformance**. Son intérêt dans cette étude repose notamment sur sa simplicité et sur la possibilité d'interpréter l'influence des variables explicatives à partir des coefficients estimés.

Le modèle est entraîné sur l'ensemble d'apprentissage à partir des 23 variables explicatives disponibles après prétraitement. Les prédictions obtenues sur l'ensemble de test permettent ensuite d'évaluer sa capacité à distinguer les profils Good et Bad.

Les résultats obtenus sont les suivants :

Indicateur	Résultat
Accuracy	0,718
Precision	0,717
Recall	0,761
F1-score	0,738
ROC-AUC	0,790

Tableau 4.2 — Performances de la régression logistique

La régression logistique obtient une **accuracy de 0,718**, ce qui signifie que 71,8 % des observations du jeu de test sont correctement classifiées. Le **recall atteint 0,761**, indiquant que le modèle identifie une proportion relativement importante des observations de la classe positive. Le **F1-score s'établit à 0,738**, tandis que le **ROC-AUC atteint 0,790**, ce qui traduit une capacité de discrimination satisfaisante entre les deux catégories.

Ces résultats constituent une première référence pour la comparaison avec les modèles fondés sur les arbres de décision. La régression logistique présente également un intérêt particulier pour l'interprétation des relations entre les variables explicatives et le risque, qui sera étudiée plus loin dans le rapport.

3. Random Forest

Le deuxième modèle utilisé est le **Random Forest**, une méthode d'apprentissage supervisé fondée sur la combinaison de plusieurs arbres de décision. Chaque arbre est construit à partir d'un échantillon des données et d'un sous-ensemble de variables, puis les prédictions sont agrégées afin d'obtenir la classification finale.

Cette approche permet de prendre en compte des relations potentiellement non linéaires entre les variables explicatives et le niveau de risque. Elle constitue ainsi un complément à la régression logistique, dont la structure est plus simple.

Le modèle Random Forest est entraîné sur le même ensemble d'apprentissage que la régression logistique et évalué sur le même ensemble de test. Les résultats obtenus sont les suivants :

Indicateur	Résultat
Accuracy	0,722
Precision	0,717
Recall	0,772
F1-score	0,743
ROC-AUC	0,792

Tableau 4.3 — Performances du Random Forest

Le Random Forest obtient une accuracy de 0,722, légèrement supérieure à celle de la régression logistique. Son recall atteint 0,772, soit également une amélioration par rapport au modèle précédent. Le F1-score s'élève à 0,743 et le ROC-AUC à 0,792.

Les performances du Random Forest restent donc proches de celles de la régression logistique, mais le modèle présente une capacité légèrement supérieure à identifier les observations de la classe positive et une discrimination globale légèrement meilleure. Cette différence sera examinée plus précisément lors de la comparaison des trois modèles.

4. Gradient Boosting

Le troisième modèle étudié est le **Gradient Boosting**, une méthode d'apprentissage supervisé reposant également sur une combinaison d'arbres de décision. Contrairement au Random Forest, les arbres sont construits de manière séquentielle, chaque nouvel arbre cherchant à améliorer les erreurs commises par les précédents.

Cette méthode permet notamment de prendre en compte des relations non linéaires et des interactions entre les variables explicatives. Elle complète ainsi les deux approches précédentes en proposant une autre méthode fondée sur les arbres de décision.

Le modèle est entraîné sur le même ensemble d'apprentissage et évalué sur le même ensemble de test afin de permettre une comparaison cohérente avec la régression logistique et le Random Forest. Les résultats obtenus sont les suivants :

Indicateur	Résultat
Accuracy	0,719
Precision	0,719
Recall	0,760
F1-score	0,739
ROC-AUC	0,787

Tableau 4.4 — Performances du Gradient Boosting

Le Gradient Boosting obtient une **accuracy de 0,719** et une **precision de 0,719**. Son **recall atteint 0,760**, tandis que son **F1-score s'établit à 0,739**. Le **ROC-AUC atteint 0,787**.

Les performances obtenues sont très proches de celles des deux autres modèles. Le Gradient Boosting présente notamment un F1-score légèrement supérieur à celui de la régression logistique, mais son ROC-AUC reste légèrement inférieur à ceux de la régression logistique et du Random Forest. La comparaison globale des performances permettra de déterminer si ces écarts sont suffisamment importants pour privilégier un modèle plutôt qu'un autre.

5. Comparaison des modèles

Afin de comparer les trois approches de manière homogène, leurs performances sont regroupées dans le tableau suivant. Les mêmes indicateurs sont utilisés pour l'ensemble des modèles : l'accuracy, la precision, le recall, le F1-score et le ROC-AUC.

Modèle	Accuracy	Precision	Recall	F1-score	ROC-AUC
Régression logistique	0,718	0,717	0,761	0,738	0,790
Random Forest	0,722	0,717	0,772	0,743	0,792
Gradient Boosting	0,719	0,719	0,760	0,739	0,787

Tableau 4.5 — Comparaison des performances des modèles

Les résultats montrent que les trois modèles présentent des performances relativement proches. Le Random Forest obtient les meilleurs résultats sur l'accuracy, le recall, le F1-score et le ROC-AUC. Il atteint notamment un ROC-AUC de 0,792, contre 0,790 pour la régression logistique et 0,787 pour le Gradient Boosting.

La différence entre les modèles reste toutefois limitée. Le Gradient Boosting obtient la meilleure precision avec 0,719, mais cet avantage ne se retrouve pas sur les autres indicateurs. Le Random Forest apparaît ainsi comme le modèle présentant les performances globales les plus élevées sur le jeu de test.

Ces résultats doivent néanmoins être complétés par une analyse des erreurs de classification. Dans le contexte du credit scoring, la nature des erreurs commises peut en effet être aussi importante que la performance globale du modèle.

6. Analyse des erreurs

L'évaluation des modèles ne peut pas se limiter aux indicateurs de performance globale. Dans le contexte du credit scoring, il est également important d'examiner la nature des erreurs commises par les modèles. Une matrice de confusion permet notamment de distinguer les observations correctement classées des erreurs de classification.




Figure 4.6.1 – Matrice de confusion du modèle de régression logistique




Figure 4.6.2 – Matrice de confusion du modèle Random Forest




Figure 4.6.3 – Matrice de confusion du modèle Gradient Boosting

Deux types d’erreurs doivent particulièrement être distingués : les faux positifs, correspondant aux observations prédites dans une classe alors qu’elles appartiennent à l’autre, et les faux négatifs, correspondant au cas inverse. Cette distinction permet de mieux comprendre les conséquences des prédictions erronées et complète les résultats présentés précédemment.

L’analyse des matrices de confusion des trois modèles permet ainsi de comparer leur comportement au-delà de leurs scores globaux. Elle permet notamment d’identifier si les différences observées entre les modèles proviennent principalement de leur capacité à détecter une classe ou à éviter certaines erreurs.

7. Courbes ROC et capacité discriminante

La courbe ROC permet d’évaluer la capacité des modèles à distinguer les deux catégories de la variable **RiskPerformance** pour différents seuils de classification. Elle met en relation le taux de vrais positifs avec le taux de faux positifs.

Cette analyse complète les métriques présentées précédemment, notamment le ROC-AUC. Plus l’aire sous la courbe est élevée, plus le modèle possède une bonne capacité à différencier les deux catégories de profils.




Figure 4.7 – Courbes ROC des trois modèles de classification

Les trois modèles présentent des courbes ROC relativement proches. Le Random Forest obtient le ROC-AUC le plus élevé avec 0,792, suivi de la régression logistique avec 0,790, puis du Gradient Boosting avec 0,787.

Les écarts restent cependant faibles. Les trois modèles présentent donc une capacité discriminante comparable sur l'échantillon de test. Le Random Forest conserve néanmoins un léger avantage selon cet indicateur.

8. Choix du modèle final

La comparaison des performances permet de déterminer le modèle le plus adapté à la classification des profils de risque. Les trois approches présentent des résultats relativement proches, mais le Random Forest obtient les meilleures performances globales.

Il atteint une **accuracy de 0,722**, un **recall de 0,772**, un **F1-score de 0,743** et un **ROC-AUC de 0,792**. Il obtient ainsi les meilleurs résultats pour quatre des cinq indicateurs retenus. Le Gradient Boosting présente quant à lui la meilleure précision, avec 0,719, mais cet avantage reste limité.

Le Random Forest est donc retenu comme modèle final de l'étude, compte tenu de ses performances globales légèrement supérieures. Ce choix ne signifie toutefois pas que les différences avec les autres modèles sont importantes : les écarts restent faibles et les trois méthodes présentent une capacité de classification comparable.

Le Random Forest sera par conséquent utilisé comme modèle de référence pour approfondir l'analyse de l'importance des variables et comprendre les caractéristiques qui contribuent le plus à la distinction entre les profils Good et Bad.

V – Interprétation des résultats

1. Importance des variables dans les modèles d'arbre

Le choix du Random Forest comme modèle final permet d'approfondir l'analyse des variables utilisées pour la classification. Les modèles fondés sur les arbres de décision permettent en effet d'estimer l'importance relative des variables dans la construction des prédictions.




Figure 5.1 – Importance des variables dans le modèle Random Forest

L'analyse de l'importance des variables du Random Forest met en évidence plusieurs caractéristiques particulièrement importantes dans la distinction entre les profils Good et Bad. Parmi les variables les plus contributives figurent notamment **ExternalRiskEstimate**, **NetFractionRevolvingBurden**, **AverageMInFile** et **MSinceOldestTradeOpen**.

Ces résultats sont cohérents avec les observations réalisées lors de l'analyse descriptive. Les variables liées à l'évaluation du risque, à l'ancienneté de l'historique de crédit et à l'utilisation du crédit apparaissent ainsi comme des éléments importants pour la classification des profils.

L'importance d'une variable doit toutefois être interprétée avec prudence. Elle indique qu'une variable contribue fortement aux décisions du modèle, mais ne signifie pas qu'elle exerce nécessairement un effet causal sur le niveau de risque. De plus, lorsque plusieurs variables sont fortement corrélées, leur importance peut refléter en partie une information commune.

2. Comparaison des variables entre Good et Bad

Afin de compléter l'analyse de l'importance des variables dans le Random Forest, les caractéristiques des profils **Good** et **Bad** sont comparées pour plusieurs variables particulièrement importantes.

Les différences les plus marquées concernent notamment **ExternalRiskEstimate**. Sa moyenne atteint 76,54 pour les profils Good contre 67,96 pour les profils Bad. Une différence importante est également observée pour **AverageMlnFile**, avec respectivement 86,82 et 71,11.

L'ancienneté de l'historique de crédit présente également un écart notable. **MSinceOldestTradeOpen** affiche une moyenne de 220,03 mois chez les Good contre 180,89 mois chez les Bad.

À l'inverse, **NetFractionRevolvingBurden** présente une valeur moyenne nettement plus élevée chez les profils Bad, avec 43,47 contre 24,55 chez les Good. Cette différence suggère une utilisation plus importante du crédit revolving parmi les profils classés Bad.

La comparaison met ainsi en évidence des différences entre les deux catégories sur plusieurs dimensions du comportement de crédit. Ces résultats permettent de donner un contexte aux variables identifiées comme importantes par le Random Forest, sans pour autant établir de relation causale.

3. Interprétation de la régression logistique

La régression logistique présente un intérêt particulier pour l'interprétation des résultats, car elle permet d'étudier le sens de l'association entre les variables explicatives et la probabilité d'appartenir à une catégorie donnée. Contrairement aux modèles fondés sur les arbres, dont l'interprétation repose notamment sur l'importance des variables, la régression logistique permet d'examiner directement les coefficients estimés.

Un coefficient positif indique qu'une augmentation de la variable est associée à une augmentation des **log-odds** d'appartenance à la classe considérée, toutes choses égales par ailleurs. À l'inverse, un coefficient négatif indique une association dans le sens opposé. Les coefficients peuvent également être transformés en **odds ratios**, ce qui facilite leur interprétation.

Variable	Coefficient	Odds ratio
NumInqLast6Mexcl7days	-0,585	0,557
ExternalRiskEstimate	-0,508	0,602
NumSatisfactoryTrades	-0,324	0,723
AverageMlnFile	-0,257	0,773
MSinceMostRecentInqexcl7days	-0,220	0,802
PercentTradesNeverDelq	-0,157	0,855
NetFractionRevolvingBurden	0,283	1,327
NumInqLast6M	0,747	2,111

Tableau 5.3 – Coefficients et odds ratios de la régression logistique

Dans le cadre de cette étude, l'interprétation des coefficients permet notamment de mettre en perspective les résultats obtenus précédemment. Les variables liées à l'estimation du risque, à l'historique de crédit et à l'utilisation des crédits peuvent ainsi être étudiées en fonction du sens et de l'intensité de leur association avec la classe prédite.

Cette interprétation doit néanmoins rester prudente. Un coefficient statistiquement associé à la variable cible ne permet pas d'établir une relation causale. De plus, les corrélations importantes observées entre certaines variables peuvent rendre l'interprétation individuelle des coefficients plus délicate.

4. Lecture économique et financière des résultats

Les résultats obtenus permettent de mettre en évidence plusieurs dimensions du comportement financier associées à la classification des emprunteurs. L'objectif n'est pas d'interpréter ces relations comme des liens de causalité, mais de comprendre économiquement les différences observées entre les profils Good et Bad.

L'estimation externe du risque apparaît comme l'un des éléments les plus discriminants. **ExternalRiskEstimate** présente une moyenne sensiblement plus élevée chez les profils **Good** que chez les profils **Bad**. Cette variable synthétise ainsi une information déjà associée au niveau de risque et constitue logiquement un élément important pour la classification.

L'ancienneté et la profondeur de l'historique de crédit constituent également des dimensions importantes. Les profils Good présentent en moyenne un historique de crédit plus ancien, notamment à travers **MSinceOldestTradeOpen** et **AverageMInFile**. Un historique plus long fournit davantage d'informations sur le comportement financier passé de l'emprunteur et permet donc de mieux caractériser son profil.

À l'inverse, les variables relatives à l'utilisation du crédit revolving présentent des niveaux plus élevés chez les profils **Bad**. C'est notamment le cas de **NetFractionRevolvingBurden**. Une utilisation plus importante des capacités de crédit disponibles apparaît ainsi associée aux profils présentant le niveau de risque le plus élevé dans la base étudiée.

Les résultats montrent également l'intérêt de considérer simultanément plusieurs dimensions du comportement financier. Le risque ne semble pas être associé à une caractéristique unique, mais à un ensemble d'informations relatives à l'historique de crédit, à son utilisation et aux indicateurs de risque disponibles.

Ces observations permettent de donner une interprétation économique aux résultats des modèles. Elles doivent cependant être distinguées d'une interprétation causale : les modèles identifient des associations utiles à la prédiction, mais ne permettent pas de conclure qu'une modification d'une variable entraînerait nécessairement une modification du risque.

5. Limites de l'interprétation

L'interprétation des résultats obtenus doit être réalisée avec certaines précautions. Les modèles permettent d'identifier des variables associées à la classification des profils **Good** et **Bad**, mais ils ne permettent pas d'établir de relations de causalité. Une variable importante pour la prédiction ne doit donc pas être considérée comme une cause directe du risque de crédit.

L'interprétation est également limitée par les relations entre certaines variables explicatives. Comme l'a montré l'analyse des corrélations, plusieurs variables présentent des corrélations élevées et peuvent

ainsi contenir une information similaire. Cette redondance peut notamment compliquer l'interprétation individuelle des coefficients de la régression logistique.

Par ailleurs, l'importance des variables obtenue avec les modèles d'arbre doit être interprétée comme une mesure de leur contribution aux prédictions du modèle. Elle ne constitue pas une mesure directe de leur influence économique ou financière sur le risque.

Enfin, les résultats obtenus sont spécifiques au jeu de données étudié et aux méthodes de modélisation retenues. Ils ne peuvent donc pas être généralisés automatiquement à l'ensemble des emprunteurs ou à d'autres bases de données. Une validation sur d'autres échantillons et l'utilisation de méthodes d'interprétation complémentaires permettraient d'approfondir ces résultats.

VI – Evaluation critique et limites du modèle

1. Performance prédictive

Les résultats obtenus montrent que les trois modèles étudiés présentent des performances relativement proches sur l'échantillon de test. Le Random Forest obtient les meilleurs résultats globaux avec une **accuracy de 0,722**, un **recall de 0,772**, un **F1-score de 0,743** et un **ROC-AUC de 0,792**. La régression logistique et le Gradient Boosting obtiennent des performances légèrement inférieures, avec respectivement un **ROC-AUC de 0,790 et 0,787**.

Ces résultats montrent que les modèles parviennent à distinguer les deux catégories de risque, mais que leur capacité prédictive reste modérée. Un **ROC-AUC** proche de **0,8** traduit une capacité de discrimination satisfaisante, sans pour autant permettre une séparation parfaite entre les profils **Good** et **Bad**.

L'écart limité entre les trois modèles constitue également un résultat important. Le recours à des méthodes plus complexes, comme le Random Forest ou le Gradient Boosting, n'entraîne pas ici une amélioration considérable par rapport à la régression logistique. Le choix du modèle final doit donc prendre en compte non seulement la performance prédictive, mais également l'interprétabilité et les contraintes propres à l'utilisation d'un modèle de credit scoring.

2. Déséquilibre et coût des erreurs

Dans une problématique de credit scoring, toutes les erreurs de classification ne présentent pas nécessairement les mêmes conséquences. Une erreur consistant à considérer comme peu risqué un emprunteur présentant en réalité un profil **Bad** peut notamment entraîner une décision de crédit plus risquée pour l'établissement prêteur.

À l'inverse, classer un profil **Good** comme **Bad** peut conduire à refuser ou limiter l'accès au crédit d'un emprunteur qui présente pourtant un niveau de risque acceptable. Le modèle doit donc trouver un compromis entre la détection des profils risqués et la limitation des classifications incorrectes.

Les résultats obtenus montrent notamment un **recall** relativement élevé pour les trois modèles, compris entre **0,760 et 0,772**. Cet indicateur doit cependant être interprété conjointement avec la précision et

la matrice de confusion afin d'évaluer concrètement les compromis réalisés entre les différentes catégories d'erreurs.

Cette question souligne l'importance du choix du seuil de classification. Dans une application réelle, celui-ci pourrait être adapté en fonction du coût économique associé aux différents types d'erreurs plutôt que d'être déterminé uniquement à partir d'un seuil standard.

3. Interprétabilité

L'interprétabilité constitue un enjeu important dans le domaine du credit scoring. Une bonne performance prédictive ne suffit pas nécessairement à justifier l'utilisation d'un modèle dans un contexte de décision financière. Il est également nécessaire de pouvoir comprendre les facteurs qui contribuent aux prédictions.

De ce point de vue, la régression logistique présente un avantage important grâce à l'interprétation directe de ses coefficients et de ses odds ratios. Elle permet notamment d'étudier le sens de l'association entre les variables explicatives et la probabilité d'appartenance à une classe.

Le Random Forest offre quant à lui une capacité d'interprétation différente grâce à l'importance des variables. L'analyse présentée en section 4.1 permet ainsi d'identifier les caractéristiques qui contribuent le plus aux prédictions du modèle. Cependant, cette mesure ne fournit pas à elle seule une explication complète de chaque décision individuelle.

Le choix du Random Forest comme modèle final constitue donc un compromis entre performance prédictive et interprétabilité. La régression logistique demeure néanmoins particulièrement utile pour approfondir l'interprétation statistique et économique des relations observées.

4. Limites des données

L'utilisation du jeu de données HELOC présente plusieurs limites qu'il convient de prendre en compte dans l'interprétation des résultats. La base fournit un ensemble riche de variables relatives à l'historique et au comportement de crédit, mais elle ne contient pas nécessairement l'ensemble des informations susceptibles d'influencer le risque d'un emprunteur.

Certaines dimensions économiques et financières peuvent notamment être absentes de la base, telles que l'évolution des revenus, la situation professionnelle, les charges courantes ou encore certains éléments relatifs à la situation financière globale de l'emprunteur. L'absence de ces informations peut limiter la capacité des modèles à expliquer certaines situations.

La présence initiale de valeurs particulières et de valeurs manquantes constitue également une difficulté. Les traitements effectués permettent d'obtenir une base exploitable pour la modélisation, mais l'imputation des valeurs manquantes peut introduire une certaine simplification de l'information disponible.

Enfin, les résultats obtenus dépendent de la population représentée dans le jeu de données. Ils ne peuvent donc pas être considérés automatiquement comme représentatifs de l'ensemble des emprunteurs ou de l'ensemble des marchés du crédit.

5. Limites méthodologiques

Plusieurs limites méthodologiques doivent également être prises en considération. Tout d'abord, les performances obtenues sont évaluées sur un échantillon de test provenant du même jeu de données que celui utilisé pour l'apprentissage. Même si la séparation entre apprentissage et test permet d'évaluer la généralisation du modèle, elle ne garantit pas que les performances seront identiques sur une population différente.

Ensuite, les trois méthodes étudiées ne couvrent qu'une partie des approches possibles en classification. D'autres algorithmes pourraient être utilisés afin de rechercher une amélioration des performances ou d'étudier différemment les relations entre les variables.

Le choix des paramètres des modèles constitue également un élément susceptible d'influencer les résultats. Une optimisation plus approfondie des hyperparamètres pourrait éventuellement améliorer les performances obtenues.

Enfin, l'étude repose principalement sur des métriques globales telles que **l'accuracy**, **le F1-score** et **le ROC-AUC**. Une analyse plus complète pourrait intégrer des méthodes d'évaluation complémentaires, notamment une validation croisée ou une analyse plus détaillée de la calibration des probabilités prédites.

6. Pistes d'amélioration

Plusieurs pistes peuvent être envisagées afin d'améliorer cette étude. Une première possibilité consisterait à approfondir l'optimisation des modèles, notamment par une recherche plus systématique des hyperparamètres et par l'utilisation d'une validation croisée.

Une deuxième piste serait d'étudier davantage le choix du seuil de classification. Dans une application réelle de credit scoring, le seuil pourrait être défini en fonction du coût relatif des différentes erreurs plutôt qu'à partir d'un seuil standard. Cette approche permettrait d'adapter le modèle aux objectifs spécifiques d'un établissement prêteur.

L'utilisation de méthodes d'interprétabilité complémentaires pourrait également être envisagée. Elles permettraient notamment de mieux expliquer les prédictions individuelles des modèles d'arbres et de compléter l'analyse de l'importance globale des variables.

Enfin, l'ajout de nouvelles sources de données pourrait permettre d'enrichir l'information disponible sur les emprunteurs. Des variables économiques, financières ou comportementales supplémentaires pourraient ainsi être intégrées afin d'évaluer leur apport à la prédiction du risque.

Ces améliorations permettraient de prolonger le travail réalisé et de se rapprocher progressivement des problématiques rencontrées dans des applications professionnelles du credit scoring.

VII – Conclusion

1. Réponse à la problématique

Cette étude avait pour objectif d'analyser dans quelle mesure les caractéristiques disponibles dans le jeu de données HELOC permettent de distinguer les profils présentant un risque de crédit plus ou moins élevé. Pour répondre à cette problématique, trois méthodes de classification ont été comparées : la régression logistique, le Random Forest et le Gradient Boosting.

Les résultats montrent que les variables relatives à l'évaluation du risque, à l'ancienneté de l'historique de crédit et à l'utilisation du crédit jouent un rôle important dans la distinction entre les profils Good et Bad. Les modèles parviennent ainsi à identifier des différences significatives entre les deux catégories, même si leur capacité prédictive reste imparfaite.

Le Random Forest est finalement retenu comme modèle de référence en raison de ses performances légèrement supérieures. Avec un **ROC-AUC de 0,792**, il présente la meilleure capacité discriminante parmi les trois modèles étudiés.

2. Principaux résultats

La comparaison des modèles met en évidence des performances relativement proches. Le Random Forest obtient les meilleurs résultats sur **l'accuracy (0,722)**, **le recall (0,772)**, **le F1-score (0,743)** et **le ROC-AUC (0,792)**. La régression logistique obtient un **ROC-AUC de 0,790**, tandis que le Gradient Boosting atteint **0,787**.

L'analyse des variables confirme l'importance de plusieurs caractéristiques du profil de crédit. **ExternalRiskEstimate**, **AverageMInFile**, **MSinceOldestTradeOpen** et **NetFractionRevolvingBurden** figurent notamment parmi les variables les plus importantes et présentent des différences marquées entre les profils **Good** et **Bad**.

L'étude met également en évidence l'intérêt de combiner plusieurs approches. La régression logistique apporte une lecture statistique des associations entre les variables et la classification, tandis que les modèles d'arbres permettent d'identifier les caractéristiques contribuant le plus aux prédictions.

3. Apports du projet

Ce projet a permis de mettre en œuvre une démarche complète d'analyse de données appliquée au credit scoring, depuis la préparation et l'exploration de la base jusqu'à la construction et l'évaluation de plusieurs modèles de classification.

Il a également permis de mettre en évidence l'importance de ne pas considérer uniquement la performance prédictive lors de l'évaluation d'un modèle. L'analyse des erreurs, l'interprétabilité des variables et les limites des données constituent des dimensions essentielles dans une problématique de décision financière.

Enfin, la comparaison de méthodes statistiques et d'algorithmes d'apprentissage automatique permet de montrer les complémentarités entre différentes approches de modélisation. Le projet fournit ainsi

une première expérience de mise en œuvre d’une problématique de machine learning dans un contexte financier.

4. Perspectives

Plusieurs prolongements pourraient être envisagés. L’optimisation plus approfondie des hyperparamètres, l’utilisation d’une validation croisée et l’étude de méthodes supplémentaires permettraient notamment d’évaluer si les performances peuvent être améliorées.

Une attention particulière pourrait également être portée à l’interprétabilité des prédictions individuelles et à la calibration des probabilités produites par les modèles. Dans une application réelle, le choix du seuil de décision pourrait par ailleurs être adapté au coût relatif des différentes erreurs de classification.

Enfin, l’enrichissement de la base avec des informations économiques et financières complémentaires constituerait une piste importante. Cela permettrait d’évaluer si l’ajout de nouvelles caractéristiques améliore la capacité des modèles à identifier les profils présentant un risque de crédit élevé.

Le travail réalisé constitue ainsi une première base solide pour approfondir l’utilisation des méthodes statistiques et de l’apprentissage automatique dans l’analyse et la gestion du risque de crédit.

VIII – Sources et références

1. Données

FICO. Explainable Machine Learning Challenge – Home Equity Line of Credit (HELOC) Dataset. Jeu de données utilisé dans le cadre de l’étude sur le risque de crédit.

2. Méthodes et outils

McKinney, W. Python for Data Analysis. 3rd edition, O’Reilly Media, 2022. Ouvrage de référence utilisé pour les méthodes de manipulation, de préparation et d’analyse des données avec Python, notamment avec la bibliothèque pandas.

Scikit-learn. LogisticRegression – scikit-learn documentation. Documentation officielle relative à l’implémentation de la régression logistique utilisée pour la classification.

Scikit-learn. Ensemble methods – scikit-learn documentation. Documentation officielle relative aux méthodes d’ensemble, notamment **RandomForestClassifier** et **GradientBoostingClassifier**, utilisées dans l’étude.

3. Références institutionnelles

Basel Committee on Banking Supervision (BCBS). Principles for the management of credit risk. Banque des règlements internationaux (BIS), 2025. Référence utilisée pour situer l'étude dans le cadre général de la gestion et de la mesure du risque de crédit.

Bank for International Settlements (BIS). General credit risk management – Basel Consolidated Guidelines. Référence institutionnelle relative à la gestion, la mesure et au suivi du risque de crédit.

Annexes

Annexe A – Description complète des variables

Variable	Description
ExternalRiskEstimate	Estimation externe du risque
MSinceOldestTradeOpen	Nombre de mois depuis l'ouverture du compte le plus ancien
NumSatisfactoryTrades	Nombre de transactions satisfaisantes
NumTrades60Ever2DerogPubRec	Nombre de transactions avec retard/dérogation ou événement public enregistré à 60 jours
NumTrades90Ever2DerogPubRec	Nombre de transactions avec retard/dérogation ou événement public enregistré à 90 jours
PercentTradesNeverDelq	Pourcentage de transactions n'ayant jamais été en retard
MaxDelq2PublicRecLast12M	Niveau maximal de délinquance / événement public récent
MaxDelqEver	Niveau maximal de délinquance observé
NumTotalTrades	Nombre total de transactions
NumTradesOpeninLast12M	Nombre de transactions ouvertes au cours des 12 derniers mois
PercentTradesWBalance	Pourcentage de transactions avec solde
NumInqLast6M	Nombre de demandes de crédit sur les 6 derniers mois
NumInqLast6Mexcl7days	Nombre de demandes sur les 6 derniers mois hors 7 derniers jours
NumRevolvingTradesWBalance	Nombre de crédits revolving avec solde
NumInstallTradesWBalance	Nombre de crédits à tempérament avec solde
PercentInstallTrades	Pourcentage de crédits à tempérament
MSinceMostRecentInqexcl7days	Mois depuis la demande de crédit la plus récente hors 7 derniers jours
MSinceMostRecentDelq	Mois depuis le dernier incident de paiement
MSinceMostRecentTradeOpen	Mois depuis l'ouverture de la transaction la plus récente
NetFractionRevolvingBurden	Charge nette liée au crédit revolving
NetFractionInstallBurden	Charge nette liée aux crédits à tempérament
NumBank2NatlTradesWHighUtilization	Nombre de crédits bancaires/nationaux avec utilisation élevée
PercentTradesNeverDelq	Pourcentage de transactions jamais en défaut

Annexe B – Statistiques descriptives complètes

Variable	N	Moyenne	Ecart-type	Min	Q1(25%)	Médiane	Q3(75%)	Max
ExternalRiskEstimate	9 861	72,06	9,87	33	64	72	80	94
MSinceOldestTradeOpen	9 632	200,77	97,95	2	135	186	257	803
MSinceMostRecentTradeOpen	9 871	9,59	12,96	0	3	6	12	383
AverageMinFile	9 871	78,78	34,07	4	57	76	97	383
NumSatisfactoryTrades	9 871	21,12	11,32	0	13	20	28	79
NumTrades60Ever2DerogPubRec	9 871	0,58	1,24	0	0	0	1	19
NumTrades90Ever2DerogPubRec	9 871	0,38	0,99	0	0	0	0	19
PercentTradesNeverDelq	9 871	92,36	11,77	0	89	97	100	100
MSinceMostRecentDelq	5 031	21,88	20,81	0	5	15	34	83
MaxDelq2PublicRecLast12M	9 871	5,76	1,64	0	5	6	7	9
MaxDelqEver	9 871	6,37	1,85	2	6	6	8	8
NumTotalTrades	9 871	22,64	13,00	0	13	21	30	104
NumTradesOpeninLast12M	9 871	1,86	1,83	0	0	1	3	19
PercentInstallTrades	9 871	34,62	17,95	0	21	33	45	100
MSinceMostRecentInqexcl7days	7 540	2,48	4,76	0	0	0	3	24
NumInqLast6M	9 871	1,46	2,14	0	0	1	2	66
NumInqLast6Mexcl7days	9 871	1,40	2,10	0	0	1	2	66
NetFractionRevolvingBurden	9 685	34,86	28,90	0	9	29	56	232
NetFractionInstallBurden	6 452	68,54	24,90	0	53	74	87	471
NumRevolvingTradesWBalance	9 715	4,10	3,02	0	2	3	5	32
NumInstallTradesWBalance	9 010	2,48	1,63	1	1	2	3	23
NumBank2NatlTradesWHighUtilization	9 288	1,09	1,54	0	0	1	2	18
PercentTradesWBalance	9 853	66,45	22,04	0	50	67	83	100

Annexe C – Résultats détaillés de la régression logistique

Variable	Coefficient	Odds ratio
NumInqLast6Mexcl7days	-0,585	0,557
ExternalRiskEstimate	-0,508	0,602
NumSatisfactoryTrades	-0,324	0,723
AverageMInFile	-0,257	0,773
MSinceMostRecentInqexcl7days	-0,220	0,802
PercentTradesNeverDelq	-0,157	0,855
MaxDelq2PublicRecLast12M	-0,096	0,908
MaxDelqEver	-0,085	0,919
MSinceMostRecentDelq	-0,079	0,924
MSinceOldestTradeOpen	-0,065	0,937
NumTrades60Ever2DerogPubRec	-0,064	0,938
PercentTradesWBalance	-0,057	0,945
NumInstallTradesWBalance	-0,042	0,959
NumTotalTrades	-0,014	0,986
NumTradesOpeninLast12M	0,037	1,040
NumTrades90Ever2DerogPubRec	0,039	1,040
NetFractionInstallBurden	0,057	1,059
MSinceMostRecentTradeOpen	0,088	1,092
NumBank2NatlTradesWHighUtilization	0,145	1,156
NumRevolvingTradesWBalance	0,155	1,168
PercentInstallTrades	0,185	1,203
NetFractionRevolvingBurden	0,283	1,327
NumInqLast6M	0,747	2,111

Annexe D – Scripts et éléments techniques

Fichier	Fonction
01_exploration.ipynb	Exploration initiale, structure de la base et analyse descriptive
02_preprocessing.ipynb	Traitement des valeurs particulières, valeurs manquantes et préparation de la base
03_modelisation.ipynb	Construction et entraînement des modèles de classification

La préparation des données repose sur plusieurs étapes successives : vérification de la structure de la base, identification des valeurs particulières, remplacement des codes **-7**, **-8** et **-9** par des valeurs manquantes, puis traitement des valeurs manquantes avant la modélisation.

Les variables sont ensuite séparées entre variables explicatives et variable cible **RiskPerformance**. La base est divisée en échantillons d'entraînement et de test afin d'évaluer les modèles sur des observations non utilisées lors de leur apprentissage.

Trois modèles de classification ont été implémentés :

- Une régression logistique
- Un Random Forest
- Un Gradient Boosting

Les modèles sont évalués à partir de **l'accuracy**, de la précision, du **recall**, du **F1-score** et du **ROC-AUC**. Les matrices de confusion et les courbes ROC complètent cette évaluation.

Le projet a été réalisé en Python, principalement à l'aide des bibliothèques dédiées à la manipulation et à l'analyse des données ainsi qu'à l'apprentissage automatique. Les traitements ont été réalisés dans des notebooks Jupyter.